

Le Guide Ultime de l'Optimisation (Fine-tuning) des LLMs appliquée au contexte académique et administratif

Projet Inter-Promo SID - Équipe Concours CNRS

7 janvier 2026

Table des matières

1	Introduction : Du Généraliste au Spécialiste	2
2	L'Ingénierie des Données : La Pierre Angulaire	2
2.1	Le défi des formats bruts (PDF et HTML)	2
2.2	Pipeline de nettoyage et formatage	2
2.2.1	Algorithme de traitement (Pseudo-code)	2
3	Technologies de Fine-Tuning : PEFT et LoRA	3
3.1	PEFT (Parameter-Efficient Fine-Tuning)	3
3.2	LoRA (Low-Rank Adaptation)	3
4	Architecture Appliquée : Hybridation RAG + Fine-tuning	3
4.1	La répartition des rôles	3
5	Défis et Opportunités	4
5.1	L'Hallucination	4
5.2	L'Oubli Catastrophique	4
6	Conclusion	4

1 Introduction : Du Généraliste au Spécialiste

L'avènement des grands modèles de langage (LLMs) comme GPT-4 ou Llama-3 a transformé le paysage de l'intelligence artificielle. Cependant, ces modèles sont des **généralistes** : ils possèdent une culture immense mais manquent de contexte spécifique.

Le *Fine-tuning* (ajustement fin) est le processus technique permettant de transformer ce généraliste en un spécialiste expert d'un domaine précis. Dans le cadre de notre projet "**Auditions CNRS**", l'objectif est de passer d'un modèle qui "sait parler français" à un modèle qui "sait agir comme un jury de concours administratif".

Ce rapport explore les technologies, la préparation des données et l'architecture hybride nécessaire pour mener à bien ce projet.

2 L'Ingénierie des Données : La Pierre Angulaire

Contrairement à une idée reçue, la performance d'un modèle fine-tuné dépend à 80% de la qualité des données et à 20% de l'algorithme. C'est l'adage "*Garbage In, Garbage Out*".

2.1 Le défi des formats bruts (PDF et HTML)

Les documents sources (guides du candidat, fiches de postes) sont souvent non structurés. Un PDF est visuel, pas sémantique. Il contient du "bruit" numérique qui peut empoisonner l'apprentissage du modèle.

Exemple de bruit identifié dans le Guide 2025 :

- En-têtes et pieds de page répétitifs ("Guide du candidat 2025" sur chaque page).
- Numéros de page isolés.
- Césures de mots en fin de ligne (ex : "infor- mation").

2.2 Pipeline de nettoyage et formatage

Pour que le modèle apprenne, nous devons transformer les documents bruts en un format structuré, généralement le **JSONL** (JSON Lines), sous forme de paires *Instruction* / *Réponse*.

2.2.1 Algorithme de traitement (Pseudo-code)

```
1 def nettoyer_pdf(texte_brut):
2     # 1. Suppression des en-tetes repetitifs
3     texte = regex.sub(r"Concours externes.*2025", "", texte_brut)
4
5     # 2. Suppression des numeros de page
6     texte = regex.sub(r"\n\d+\n", "", texte)
7
8     # 3. Reparation des mots coupes (cesures)
9     texte = texte.replace("- ", "")
10
11     return texte
12
13 def creer_paire_entrainement(bloc_texte):
14     # Transformation en format Instruction/Output
```

```

15     return {
16         "instruction": "Quelles sont les conditions d'âge ?",
17         "input": "",
18         "output": bloc_texte # Texte nettoyé
19     }

```

Listing 1 – Logique de nettoyage des données PDF

3 Technologies de Fine-Tuning : PEFT et LoRA

L'entraînement complet (Full Fine-tuning) d'un modèle de 7 ou 70 milliards de paramètres est extrêmement coûteux en ressources GPU. Pour notre projet, nous utilisons des méthodes d'optimisation modernes.

3.1 PEFT (Parameter-Efficient Fine-Tuning)

Le PEFT consiste à ne pas modifier tous les paramètres du modèle, mais seulement une infime partie. Cela permet de conserver les connaissances générales du modèle tout en lui apprenant de nouvelles tâches.

3.2 LoRA (Low-Rank Adaptation)

LoRA est la technique la plus pertinente pour notre hackathon.

- **Concept** : Au lieu de modifier le "cerveau" du modèle (ses poids), on ajoute de petits modules mathématiques (matrices de rang faible) à côté.
- **Analogie** : C'est comme ajouter des post-it annotés dans un manuel scolaire plutôt que de réécrire le manuel entier.
- **Avantage** : Permet de fine-tuner un modèle Llama-3 sur une architecture modeste (comme Google Colab) en quelques heures.

4 Architecture Appliquée : Hybridation RAG + Fine-tuning

Pour le projet CNRS, nous avons identifié que le Fine-tuning seul ne suffit pas, car les données (dates, nombres de postes) changent chaque année.

4.1 La répartition des rôles

Nous proposons une architecture hybride où chaque technologie comble les lacunes de l'autre.

1. **Le RAG (Retrieval-Augmented Generation) : Le Savoir Factuel.** *Rôle* : Fournir l'information exacte et à jour. *Exemple* : "Le concours n°48 offre 1 poste au Centre Léon Robin." (Information extraite dynamiquement de la base vectorielle).
2. **Le Fine-tuning : Le Comportement et le Style.** *Rôle* : Adopter la persona du jury. *Exemple* : Au lieu de répondre "Voici l'info", le modèle fine-tuné répondra : "Candidat, au vu de votre dossier, comment justifiez-vous l'adéquation de votre profil avec les exigences du Centre Léon Robin ?" (Ton formel, inquisiteur, académique).

5 Défis et Opportunités

5.1 L'Hallucination

Le risque majeur est que le modèle invente des critères d'éligibilité. **Solution** : Augmenter la "température" du modèle vers 0 lors de l'inférence pour le rendre plus déterministe, et forcer l'utilisation du contexte RAG.

5.2 L'Oubli Catastrophique

En se spécialisant trop sur le jargon administratif du CNRS, le modèle risque de perdre sa capacité à converser normalement. **Solution** : Utiliser LoRA permet de limiter ce risque car les poids d'origine du modèle restent figés.

6 Conclusion

Le fine-tuning n'est pas une "boîte magique" où l'on déverse des fichiers PDF. C'est un processus rigoureux d'ingénierie des données.

Pour le projet Concours CNRS, l'excellence réside dans la préparation des données en amont (nettoyage des PDF/HTML) et dans l'utilisation intelligente de l'hybridation : le RAG pour la **mémoire**, et le Fine-tuning pour la **personnalité**.