

Comment réaliser le Fine-Tuning (La Technique)

Comme le modèle **Qwen2.5-14B** est gros (14 milliards de paramètres), vous ne pourrez pas faire un "Full Fine-Tuning" sur un ordinateur classique. Vous allez utiliser une technique appelée **QLoRA (Quantized Low-Rank Adaptation)**.

- **Le principe** : On gèle le cerveau principal du modèle (pour ne pas le casser) et on ajoute de petits modules adaptateurs qu'on entraîne.
- **Le matériel** : Il faut un GPU (carte graphique) avec au moins 16 Go de VRAM (ex: Nvidia T4 sur Google Colab gratuit, ou mieux une A100/L4).
- **La librairie recommandée** : Je te conseille vivement d'utiliser **Unsloth**. C'est une librairie qui rend le fine-tuning de Llama et Qwen 2x plus rapide et consomme 60% moins de mémoire.

Dans notre cas, faut-il fine-tuner ?

Pour l'agent concours CNRS, la base doit être un système de type RAG (retrieval + LLM), pas uniquement du fine-tuning.

Le fine-tuning est utile surtout pour :

- Apprendre au modèle un style ou une façon de répondre (par exemple toujours citer la source, refuser poliment sans halluciner).
- Spécialiser le modèle sur des formats de questions/réponses répétitives (FAQ typées, classification de profil, etc.).
- Légèrement améliorer la robustesse aux questions ambiguës, par exemple répondre « je ne sais pas / hors périmètre » quand les documents ne couvrent pas la question.

Pour ce hackathon, tu peux proposer :

- RAG (obligatoire) pour exploiter les 122 pages + PDFs.
- Un petit fine-tuning SFT (Supervised Fine Tuning) avec un dataset de Q/R CNRS pour :
 - Forcer le modèle à citer la source.
 - Standardiser la façon de refuser quand l'info n'est pas disponible.

Notions clés sur le fine-tuning

Quelques idées simples à transmettre aux devs :

- Full fine-tuning : on ré-entraîne tous les paramètres du modèle (14B ici) → très cher, inutile pour un hackathon.
- PEFT / LoRA / QLoRA : on ajoute de petites « couches » apprenables et on gèle le reste du modèle → beaucoup plus léger, standard pour Qwen2.5.

- SFT (Supervised Fine Tuning) : on donne des exemples (instruction, input, output) pour apprendre un comportement précis.
- DPO / RLHF : plus avancé, pour ajuster les préférences, sans doute trop lourd pour un premier projet sur quelques jours.

Recommandation pour ton groupe :

- Utiliser LoRA ou QLoRA sur Qwen/Qwen2.5-14B-Instruct via `transformers` + `peft` + éventuellement `trl` (SFTTrainer).

Comment réaliser le Fine-Tuning (La Technique)

Comme le modèle **Qwen2.5-14B** est gros (14 milliards de paramètres), vous ne pourrez pas faire un "Full Fine-Tuning" sur un ordinateur classique. Vous allez utiliser une technique appelée **QLoRA (Quantized Low-Rank Adaptation)**.

- **Le principe** : On gèle le cerveau principal du modèle (pour ne pas le casser) et on ajoute de petits modules adaptateurs qu'on entraîne.
- **Le matériel** : Il faut un GPU (carte graphique) avec au moins 16 Go de VRAM (ex: Nvidia T4 sur Google Colab gratuit, ou mieux une A100/L4).
- **La librairie recommandée** : Je te conseille vivement d'utiliser **Unsloth**. C'est une librairie qui rend le fine-tuning de Llama et Qwen 2x plus rapide et consomme 60% moins de mémoire.